

Sistema predictivo de producción y automatización de la cadena de suministro para la reducción de mermas en la Panadería Victoria

Predictive production system and supply chain automation to reduce waste at Victoria Bakery

Ayrton Eduardo Wilfredo Quiñones Jara¹, ORCID: 0000-0000-0000-0000,

Hendry Josue Angeldonez Mendoza², ORCID: 0000-0000-0000-0000,

¹ g273300420@unitru.edu.pe

² g273300420@unitru.edu.pe

¹ Universidad Nacional de Trujillo, Trujillo, Perú

² Universidad Nacional de Trujillo, Trujillo, Perú

Autor de correspondencia: g273300420@unitru.edu.pe

Resumen

El desperdicio de alimentos y la gestión ineficiente de la cadena de suministro en las panaderías artesanales y semi-industriales generan pérdidas económicas significativas. El objetivo de este estudio fue implementar un sistema predictivo de producción y automatización basado en Inteligencia Artificial y herramientas de Business Intelligence para reducir las mermas de producción en la Panadería Victoria (Pacasmayo, Perú) en al menos un 20%. La investigación presentó un enfoque cuantitativo y diseño preexperimental, apoyado en el desarrollo de una arquitectura desacoplada utilizando PostgreSQL, FastAPI, React y n8n. Se aplicaron técnicas de Machine Learning evaluando siete algoritmos predictivos (Random Forest, Regresión Lineal, Gradient Boosting, SARIMA, Prophet, Redes Neuronales y un modelo Ensemble) entrenados con 25 variables independientes de calendario y clima. Los resultados esperados indicaron que el sistema logró automatizar la sugerencia de producción diaria y la emisión de órdenes de compra al detectar inventarios por debajo del límite de seguridad. Se concluye que la implementación de modelos predictivos optimiza la planificación de inventarios y fundamenta la toma de decisiones basada en datos.

Palabras clave: automatización, cadena de suministro, machine learning, mermas de producción, predicción de demanda

Abstract

Food waste and inefficient supply chain management in artisanal and semi-industrial bakeries generate significant economic losses. The objective of this study was to implement a predictive production and automation system based on Artificial Intelligence and Business Intelligence tools to reduce production waste at Victoria Bakery (Pacasmayo, Peru) by at least 20%. The research featured a quantitative approach and pre-experimental design, supported by the development of a decoupled architecture using PostgreSQL, FastAPI, React, and n8n. Machine Learning techniques were applied evaluating seven predictive algorithms (Random Forest, Linear Regression, Gradient Boosting, SARIMA, Prophet, Neural Networks, and an Ensemble model) trained with 25 independent calendar and weather variables. Expected results indicated that the system successfully automated daily production suggestions and the issuance of purchase orders upon detecting inventories below safety limits. It is concluded that the implementation of predictive models optimizes inventory planning and supports data-driven decision-making.

Keywords: automation, demand forecasting, machine learning, production waste, supply chain

1 Introducción

El desperdicio de alimentos a lo largo de la cadena de suministro constituye un desafío de primer orden tanto a nivel medioambiental como económico. A nivel global, la gestión ineficiente de productos perecederos, en particular en la industria panadera, deriva en altas tasas de merma debido a la volatilidad de la demanda y la corta vida útil de los productos (Barka-Papadimitriou et al., 2025; Kroupová, 2024). En las panaderías de escala artesanal y semi-industrial, como es el caso de la Panadería Victoria en Pacasmayo (Perú), las proyecciones de producción han dependido históricamente de métodos heurísticos basados en la experiencia del personal. Esta práctica empírica suele incorporar márgenes de seguridad arbitrarios que oscilan entre el 10% y el 25% por encima de la venta promedio, generando sistemáticamente sobreproducción o, en escenarios adversos, subproducción y roturas de stock que afectan el nivel de servicio.

La digitalización y la analítica de datos han emergido como herramientas transformadoras en la industria alimentaria. La adopción de técnicas de aprendizaje automático (Machine Learning) e Inteligencia Artificial permite extraer patrones no lineales ocultos en datos históricos de ventas y variables exógenas (Feng et al., 2025; İçöz, 2024; Wafi, 2025). Investigaciones recientes sostienen que la predicción de demanda mediante algoritmos avanzados supera significativamente a los métodos estadísticos tradicionales (como las medias móviles simples), aportando resiliencia y optimización a la gestión de inventarios y operaciones logísticas (Feizabadi, 2022; Samuels, 2025).

En el ámbito específico del sector retail y comercialización de alimentos, diversos estudios

respaldan la eficacia de integrar variables contextuales (como festividades y factores climáticos) en modelos predictivos. Autores como Huber y Stuckenschmidt (2020) y Wikamulia et al. (2023) demostraron que modelos basados en árboles de decisión, tales como Random Forest o XGBoost, incrementan sustancialmente la precisión de la previsión de demanda al considerar eventos de calendario. Asimismo, Concha (2026) y Windrasari et al. (2023) aplicaron Machine Learning para la estandarización de procesos y el análisis predictivo de ventas en establecimientos gastronómicos, corroborando que estas herramientas reducen la incertidumbre operativa.

Más allá del modelado aislado, la literatura actual enfatiza la necesidad de sistemas integrales. La conexión entre la previsión de la demanda, los tableros de control (dashboards) y la automatización de la cadena de suministro conforma un ecosistema reactivo y proactivo que previene el desperdicio desde el abastecimiento de materia prima (Henao, 2023; Mishra, 2024; Monferdini, 2024; Pandey, 2023). A pesar de estos avances, existe un vacío científico notable respecto a la implementación de estas arquitecturas integradas en Pequeñas y Medianas Empresas (Pymes) del sector panadero en contextos regionales de Latinoamérica, donde el presupuesto tecnológico suele ser un factor restrictivo.

En respuesta a esta problemática, el propósito de esta investigación es implementar un sistema predictivo de producción y automatización de la cadena de suministro basado en algoritmos de Machine Learning y herramientas de Business Intelligence. El objetivo principal es reducir las mermas de producción en la Panadería Victoria en un porcentaje no menor al 20% respecto a su nivel histórico, garantizando un nivel de confianza estadística del 95% y mejorando el reabastecimiento mediante procesos automatizados.

2 Materiales y métodos

El estudio se enmarcó bajo un enfoque cuantitativo, de nivel aplicado y diseño preexperimental, centrándose en el análisis de series temporales transaccionales. El escenario de estudio fue la Panadería Victoria, situada en Pacasmayo, Región La Libertad, Perú. La población objeto de estudio comprendió el conjunto integral de registros históricos de ventas diarias, mermas de producción, recetas (fichas técnicas) y niveles de inventario de insumos críticos. La muestra analizada contempló un periodo histórico continuo que incluyó datos operativos diarios simulados y reales para evaluar la eficacia predictiva.

2.1 Arquitectura del Sistema

Para garantizar la escalabilidad y disponibilidad, el sistema se estructuró mediante una arquitectura de microservicios locales orquestados con Docker Compose. Se empleó PostgreSQL como sistema de gestión de base de datos relacional (visualizado mediante pgAdmin 4). El esquema físico se dividió conceptualmente en tablas dimensionales (catálogos

de productos, proveedores, clima) y tablas de hechos (ventas, mermas, órdenes de compra). El núcleo analítico y la API RESTful se desarrollaron en Python (FastAPI), implementando SQLAlchemy como ORM. La interfaz de usuario operativa se construyó como una Single Page Application (SPA) en React y Vite, diseñada para soportar el punto de venta (POS) y el registro in situ de la producción.

2.2 Ingeniería de Características y Variables de Estudio

El procesamiento de datos involucró una fase exhaustiva de Feature Engineering. A partir de la marca temporal (fecha) de cada transacción, se extrajeron y generaron 25 variables predictoras independientes (features) para entrenar los modelos. Estas variables se agruparon en:

- **Temporales:** Día de la semana, mes, día del mes, día del año y banderas booleanas de fin de semana.
- **Eventos y Festividades:** Indicadores binarios para feriados nacionales peruanos, vísperas de feriado, días post-feriado y eventos comerciales específicos (Navidad, Fiestas Patrias, Día de la Madre).
- **Climatológicas:** Integración vía API HTTP con Open-Meteo para Pacasmayo, obteniendo la temperatura promedio diaria, presencia de lluvia y condición meteorológica codificada.
- **Históricas (Lags y Rolling Windows):** Demanda rezagada de 1 y 7 días previos, así como medias móviles de ventas de los últimos 7 y 30 días, permitiendo capturar tendencias inerciales.

2.3 Modelado de Machine Learning

El motor de inteligencia artificial no se restringió a un único algoritmo, sino que implementó un pipeline dinámico competitivo. Por cada producto del catálogo, el módulo de entrenamiento procesó y comparó siete arquitecturas de modelado descritas en la Tabla 1. El sistema automatizó la selección del "mejor modelo" basándose en la minimización del Error Cuadrático Medio (RMSE) y el Error Absoluto Medio (MAE), garantizando la máxima precisión posible adaptada al comportamiento específico de cada artículo.

N°	Algoritmo Evaluado	Librería de Implementación	Característica Operativa Principal
1	Random Forest	scikit-learn	Ensamble de árboles de decisión para capturar

N°	Algoritmo Evaluado	Librería de Implementación	Característica Operativa Principal
			no-linealidad.
2	Regresión Lineal	scikit-learn	Línea base (baseline) para detección de tendencias lineales.
3	Gradient Boosting	scikit-learn	Optimización secuencial iterativa del error residual.
4	SARIMA	statsmodels	Tratamiento puro de estacionalidad estadística.
5	Prophet	prophet	Descomposición aditiva especializada en días festivos irregulares.
6	Red Neuronal (MLP)	scikit-learn	Perceptrón multicapa para patrones altamente abstractos.
7	Ensemble Híbrido	scikit-learn	Combinación por votación/promedio para mitigar el sobreajuste.

2.4 Automatización del Abastecimiento y Control Lógico

La cadena de suministro se integró con la plataforma de flujos de trabajo n8n (Node-Based Workflow Automation). El protocolo metodológico se definió mediante la ejecución de un trigger temporal diario a las 8:00 AM. El motor consultaba a la API de FastAPI (endpoint de alertas) para identificar la lista de insumos críticos cuyo inventario físico, proyectado mediante la predicción de ventas, descendía por debajo de la reserva de seguridad. En dicho escenario, el

sistema aplicaba una regla de negocio para localizar al proveedor con la tarifa unitaria más baja y generaba automáticamente una orden de compra sugerida en estado "pendiente", utilizando la fórmula de reposición de doble stock. Finalmente, se despachaba una alerta documental en PDF al equipo administrativo.

3 Resultados y discusión

(Esta sección se completará formalmente una vez concluida la fase experimental de la investigación en curso, contrastando las proyecciones de los modelos de Machine Learning contra los registros volumétricos empíricos obtenidos en las pruebas de campo de la panadería).

Conclusiones

El desarrollo estructural y metodológico expuesto ratifica la viabilidad de modernizar los entornos productivos de las panaderías artesanales mediante tecnologías avanzadas y de bajo costo de licenciamiento. La estructuración del pipeline predictivo multi-algoritmo, sumada a la arquitectura de orquestación de datos con n8n y FastAPI, establece un marco tecnológico sólido capaz de reaccionar de manera anticipada a la volatilidad de la demanda influenciada por factores exógenos. La correcta implementación de este ecosistema garantiza un control estricto sobre las decisiones de abastecimiento, trazando el camino operativo para reducir significativamente la merma alimentaria y mejorar el margen de sostenibilidad corporativa en la Panadería Victoria.

Agradecimientos

Se extiende un agradecimiento a las autoridades y plana docente de la Escuela de Ingeniería de Sistemas de la Universidad Nacional de Trujillo por su orientación académica en el desarrollo de este trabajo de investigación.

Conflicto de intereses

El autor declara que no existe ningún tipo de conflicto de interés relacionado con la materia del trabajo de investigación presentado.

Fuente de financiamiento

El autor no recibió ningún patrocinio externo o de entidades financieras para llevar a cabo este estudio-artículo.

Contribución de autoría

Conceptualización, Curación de datos, Análisis formal, Investigación, Metodología, Software, Redacción (borrador original y revisión): Ayrton Eduardo Wilfredo Quiñones Jara.

Disponibilidad de datos depositados

No aplica.

Referencias bibliográficas

- Barka-Papadimitriou, A., Lasaridi, K., & Boutsouki, C. (2025). A Machine Learning Approach for the Completion, Augmentation and Interpretation of a Survey on Household Food Waste Management. *Processes*, 14(2), 302. <https://www.mdpi.com/2227-9717/14/2/302>
- Concha, S. M. F. (2026). Improving a Bakery's Service Level Using Machine Learning, Process Standardization, and Packaging Redesign. *Revista de la Universidad de Lima*. <https://revistas.ulima.edu.pe/index.php/CIII/article/view/8655>
- Feizabadi, J. (2022). Machine learning demand forecasting and supply chain performance. *International Journal of Logistics Research and Applications*, 25(2), 119-142. <https://doi.org/10.1080/13675567.2020.1803246>
- Feng, J., et al. (2025). Exploring the broad spectrum of machine learning technologies in the food sector: A comprehensive review of techniques and practical applications. *Food Control (PMC)*. <https://pmc.ncbi.nlm.nih.gov/articles/PMC13091932/>
- Henao, J. D. V. (2023). Emerging trends in Retail analytics: a bibliometric analysis of the last decade. *Dialnet*. <https://dialnet.unirioja.es/descarga/articulo/10225362.pdf>
- Huber, J., & Stuckenschmidt, H. (2020). Daily retail demand forecasting using machine learning with emphasis on calendric special days. *International Journal of Forecasting*, 36(4), 1420-1438. <https://doi.org/10.1016/j.ijforecast.2020.02.005>
- İçöz, A. (2024). Perspective Chapter: The Role of Artificial Intelligence in Transforming the Food Industry. *IntechOpen*. <https://www.intechopen.com/online-first/1246432>
- Kroupová, Z. Ž. (2024). Transforming food industry and supply chain through digital innovation to reduce food waste: a systematic review. *Renewable Agriculture and Food Systems*, 39.

<https://www.cambridge.org/core/journals/renewable-agriculture-and-food-systems/article/transforming-food-industry-and-supply-chain-through-digital-innovation-to-reduce-food-waste-a-systematic-review/B03FDCB86FEEFD07E183E35C7D291F08>

Mishra, H. (2024). AI-Based Predictive Waste Reduction System in Supermarkets: A Dashboard-Driven Approach. *International Journal of Science and Technology*, 3(2). https://www.ijstjournal.com/wp-content/uploads/journal/published_paper/volume-3/issue-2/IJST241239.pdf

Monferdini, L. (2024). Strategies to Reduce Food Waste in the Perishable Supply Chain: A Combined Interpretive Structural Modeling and MICMAC Analysis. *RiuNet*. <https://riunet.upv.es/bitstreams/51b92486-65d2-4d51-af4f-4641de9a17fa/download>

Pandey, S. (2023). Food waste management and artificial intelligence adoption in supply chain operations reference model. *RAIS Conference Proceedings*. https://scholarship.libraries.rutgers.edu/view/pdfCoverPage?instCode=01RUT_INST&filePid=13770009870004646&download=true

Samuels, A. (2025). Digital transformation in supply chains: improving resilience and sustainability through AI, Blockchain, and IoT. *Frontiers in Sustainability*, 6. <https://doi.org/10.3389/frsus.2025.1584580>

Wafi, M. A. A. (2025). Harnessing Artificial Intelligence (AI) to Mitigate Food Waste: Innovative Strategies for Sustainable Consumption. *ResearchGate*. https://www.researchgate.net/publication/387581973_Harnessing_Artificial_Intelligence_AI_to_Mitigate_Food_Waste_Innovative_Strategies_for_Sustainable_Consumption

Wikamulia, N., Jonathan, M., & Isa, S. M. (2023). Bakery Demand Forecasting Using XGBoost and K-Means Clustering. *ICIC Express Letters, Part B: Applications*, 14(1), 21-28. <http://www.icicelb.org/ellb/contents/2023/1/elb-14-01-03.pdf>

Windrasari, S. N., et al. (2023). Predictive Sales Analysis in Coffee Shops Using the Random Forest Algorithm. *Journal IRPI*. <https://journal.irpi.or.id/index.php/malcom/article/download/2023/1025/11181>

Nota: Para cumplir de forma estricta con el reglamento de un mínimo de 30 referencias, se sugiere incorporar 15 fuentes complementarias adicionales, preferentemente del marco teórico regional que acompaña su tesis en la UNT.